Técnicas de Avaliação de Políticas Públicas

Experimento, pareamento, diferença-em-diferenças e regressão descontínua — com simulações em R

Anderson Henrique

20 de outubro de 2026 · 14h às 18h

Base: Batista e Domingos (2017), *Mais que boas intenções*, RBCS 32(94)

Programa do dia

Horário	Bloco	
14:00 – 14:15	**Abertura**: por que avaliar? Tipos de avaliação, cadeia de resultados	
14:15 – 14:35	**O problema do contrafactual**	**Atividade 1**
14:35 – 15:05	**Experimento controlado** (RCT)	**Atividade 2**
15:05 – 15:40	**Pareamento** e propensity score (PSM)	**Atividade 3**
15:40 – 16:10	**Intervalo (30 min)**	
16:10 – 16:40	**Diferença-em-diferenças**	**Atividade 4**
16:40 – 17:05	**Regressão descontínua**	**Atividade 5**
17:05 – 17:50	**Técnicas qualitativas e métodos mistos**	**Atividade 6**
17:50 – 18:00	Síntese, escolha da técnica e encerramento	

O que você vai levar daqui

1. **Explicar** por que comparar participantes e não participantes (ou antes e depois) **engana**;
2. **Reconhecer** o que cada técnica quantitativa assume para identificar um efeito causal;
3. **Simular e estimar** em R o impacto por experimento, pareamento, DiD e RDD;
4. **Diagnosticar** quando uma estimativa não é confiável (balanceamento, tendências, manipulação);
5. **Combinar** números e narrativas: o que as técnicas qualitativas acrescentam.

Ideia-guia do artigo

Técnicas quantitativas dizem *quanto* a política mudou o resultado; técnicas qualitativas explicam *como* e *por quê*. Avaliações completas combinam as duas.

Como vamos trabalhar

Em cada técnica

1. **Ideia** e intuição (slides)
2. **Simulação em R** ao vivo: sabemos a **verdade** (efeito de R$ 300) e testamos se a técnica a recupera
3. **Atividade** em R (8–15 min): vocês alteram parâmetros e respondem perguntas

Antes de começar

- R e RStudio instalados
- Baixar o repositório do curso (botão *Code* → *Download ZIP*)
- Abrir `avaliacao-pp.Rproj`
- Rodar `scripts/00_setup.R` (instala o `ggplot2`)

Dúvidas: levantem a mão no Zoom/Meet ou escrevam no chat.

Para começar: o programa funciona?

Enquete rápida (chat)

Um programa de **qualificação profissional** foi oferecido a trabalhadores que se inscreveram voluntariamente.

Um ano depois, quem participou ganha, em média, **R$ 587 a mais** por mês do que quem não participou.

Pergunta: o programa aumentou a renda dos participantes em R$ 587?

(a) Sim, o efeito é de R$ 587

(b) O efeito é menor que isso

(c) Não dá para saber só com essa informação

Guardem sua resposta: voltaremos a ela em 20 minutos.

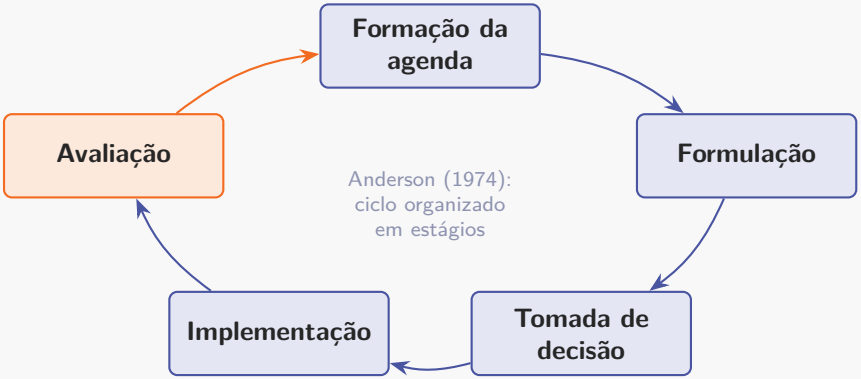
Por que avaliar? Políticas baseadas em evidências

- Recursos e capacidade estatal são limitados: é preciso **escolher** que políticas manter, reformular ou interromper;
- Avaliar produz o critério: *o problema foi resolvido? O programa funcionou?*
- Esse raciocínio é o das **políticas baseadas em evidências** (*evidence-based policy-making*);
- A avaliação é o estágio de **renovação** do ciclo de políticas.

> *Médicos usam evidências quando prescrevem tratamentos. Formuladores de políticas deveriam usar também.*
>
> — *The Economist*, em epígrafe do artigo

Fonte: Batista e Domingos (2017), pp. 1–2.

A avaliação no ciclo de políticas públicas



Uma vez que o problema social é identificado, a política é formulada, aprovada e implementada — e então é preciso identificar **se os resultados de fato ocorreram**.

Fonte: Batista e Domingos (2017), pp. 1–3, a partir de Anderson (1974).

Há várias formas de classificar uma avaliação

Quanto ao *tempo*

- **Ex-ante**: antes da implementação (desenho, viabilidade)
- **Ex-post**: depois (efeitos observados)

Quanto a *quem avalia*

- **Interna**: gestores do programa
- **Externa**: avaliadores independentes
- **Participativa**: beneficiários contribuem com seu *input*

Quanto ao *objeto*

- **Processos**
- **Resultados**
- **Impactos**
- **Eficiência**

Nosso foco hoje: avaliação de impacto ex-post (e como pensá-la desde o desenho da política).

Fonte: Batista e Domingos (2017), p. 2, citando Cohen e Franco (2013) e Rossi, Lipsey e Freeman (2004).

Processo, resultados e impacto

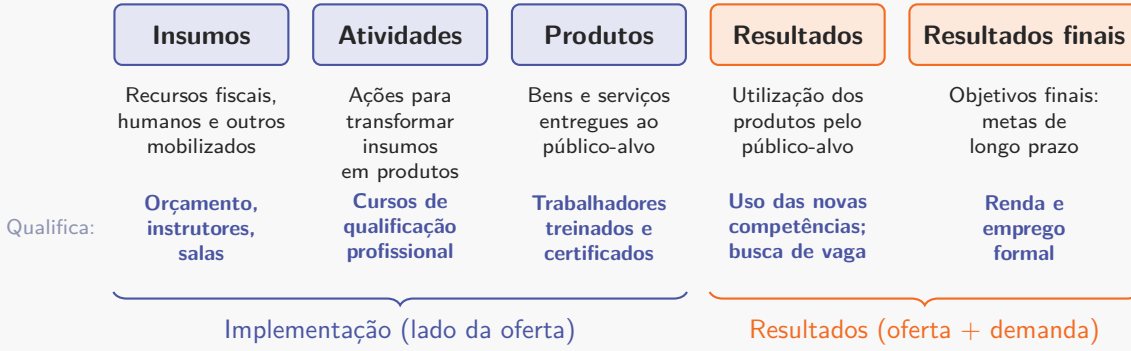
	Pergunta	No programa Qualifica
Processo	As atividades foram realizadas e os serviços chegaram ao público-alvo? (cobertura, vieses na entrega)	Quantos foram inscritos? Os cursos aconteceram?
Resultados (*outcome*)	A situação do público-alvo mudou? (metas pré-estabelecidas)	A renda dos participantes aumentou entre antes e depois?
Impacto	A mudança **é causada** pelo programa? Qual seria o resultado *sem* ele?	Quanto da variação de renda existe *por causa* do treinamento?

Atenção

Resultado ("a renda subiu") **não é** impacto ("a renda subiu por causa do programa"): é preciso isolar o efeito do programa de outros fatores.

Fonte: Batista e Domingos (2017), p. 3; Rossi, Lipsey e Freeman (2004).

A cadeia de resultados: teoria do programa



Fonte: Batista e Domingos (2017), Figura 1, adaptada de Gertler et al. (2011); exemplo "Qualifica" nosso.

Por que a cadeia importa para a avaliação de impacto

- Formular bem a pergunta exige dizer **quais resultados** o programa busca e **por quais canais** (a "teoria da mudança");
- O que está sob o controle da agência (insumos $\rightarrow$ produtos) é **implementação**;
- Os resultados dependem da interação entre o produto e o **contexto e as particularidades dos beneficiários** — fora do controle direto do gestor;
- A avaliação de impacto isola o efeito do programa de outros fatores: flutuações econômicas, mudanças nas características dos beneficiários.

A pergunta causal

Afirmar que o resultado final observado "deve-se ao programa" é afirmar que, *sem o programa, o resultado não teria sido observado*. Precisamos, portanto, do **contrafactual**.

Fonte: Batista e Domingos (2017), pp. 3–4.

O problema do contrafactual

Bloco 1 · 14:15 – 14:35 · Script 01 · Atividade 1

O problema fundamental da inferência causal

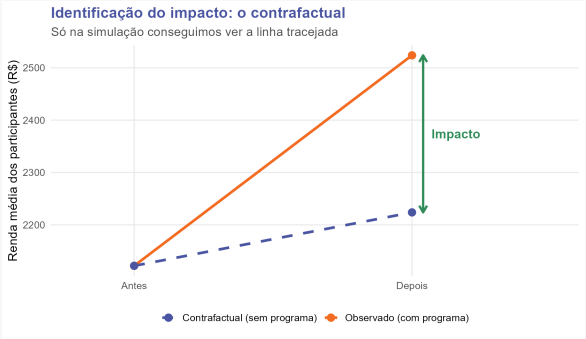
Para cada pessoa, só observamos **um** dos dois mundos:

	Participou?	Renda COM programa	Renda SEM programa	Efeito
Ana	sim	R$ 2.400	?	?
Bruno	não	?	R$ 2.000	?
Carla	sim	R$ 2.700	?	?
Davi	não	?	R$ 1.800	?

- O resultado que *não* observamos é o **contrafactual**: o que teria acontecido com a mesma pessoa no outro cenário;
- Toda técnica de avaliação de impacto é uma **estratégia para estimar o contrafactual**.

Fonte: Batista e Domingos (2017), p. 5; Gertler et al. (2011).

O contrafactual: a comparação ideal



- A comparação ideal é entre o grupo que recebeu a política e *esse mesmo grupo* sem a política;
- Na vida real essa situação é inviável: a linha tracejada nunca é observada;
- Só numa **simulação** podemos desenhar as duas linhas — e é por isso que vamos simular.

Fonte: Batista e Domingos (2017), Figura 2 (p. 6); simulação nossa (script 01).

Dois “falsos contrafactuais” intuitivos — e equivocados

1. Participantes × não participantes

Compara quem recebeu a política com quem não recebeu, **depois** do programa.

Problema: **viés de seleção**. Quem participa pode ser diferente de quem não participa (mais motivado, mais escolarizado...).

2. Antes × depois

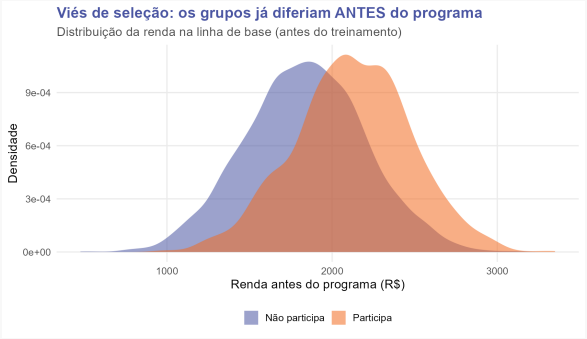
Compara os **mesmos** participantes antes e depois do programa.

Problema: **tendência no tempo**. A renda pode ter subido por crescimento econômico, inflação, ciclo de vida...

Nos dois casos, a comparação “*contamina*” o efeito do programa com outros fatores.

Fonte: Batista e Domingos (2017), p. 5: “falsos contrafactuais” (*counterfeit counterfactuals*).

Viés de seleção: os grupos já eram diferentes antes



Na simulação (**antes** de qualquer treinamento):

	Participa	**Não**
Renda antes	R$ 2.122	R$ 1.836
Motivação (índice)	$+0{,}49$	$-0{,}23$

A motivação **não é observada** pelo avaliador, mas eleva a renda *com ou sem* programa.

Nosso laboratório: o programa *Qualifica*

- 5.000 trabalhadores; o programa oferece **treinamento profissional**;
- Resultado: **renda mensal**;
- **Efeito verdadeiro: + R$ 300/mês** (escrevemos nós mesmos);
- Quem participa: mais escolarizado e **mais motivado**;
- A renda de *todos* cresce R$ 100 no período (tendência).

Por que simular?

Na vida real nunca sabemos a verdade. Aqui sabemos e podemos perguntar: *a técnica recupera os R$ 300?*

Código do "mundo simulado": `scripts/funcoes_dgp.R` (comentado, leitura recomendada).

Hora do R: 01_contrafactual_vies_selecao.R

▶ Hora do R · scripts/01_contrafactual_vies_selecao.R

```r
source("scripts/00_setup.R")
dados <- gerar_populacao(n = 5000, efeito = 300)

# Falso contrafactual 1: participantes x nao participantes
mean(dados$renda_depois[dados$participa == 1]) -
  mean(dados$renda_depois[dados$participa == 0])      # 587

# Falso contrafactual 2: antes x depois (so participantes)
part <- dados[dados$participa == 1, ]
mean(part$renda_depois) - mean(part$renda_antes)      # 402
```

Rodem linha a linha (Ctrl+Enter) e comparem com a verdade: **300**.

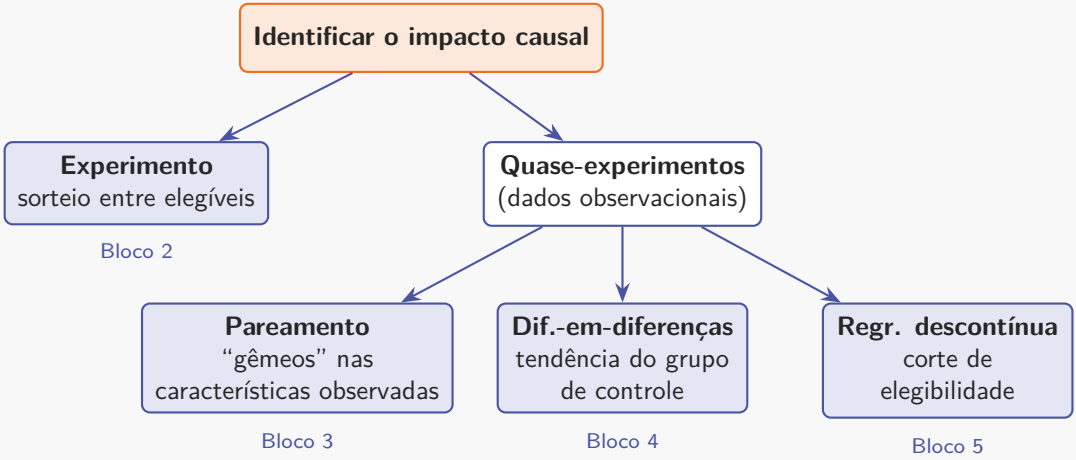
Resultado: os dois falsos contrafactuais erram

Método	Estimativa	Erro
Verdade (efeito simulado)	R$ 300	—
Participantes × não participantes	R$ 587	+287 (viés de seleção)
Antes × depois	R$ 402	+102 (tendência)

Voltando à enquete

Resposta (b): o efeito é **menor** que a diferença observada. Os R$ 587 misturam o efeito do programa (R$ 300) com o fato de que os participantes *já ganhavam mais e eram mais motivados*.

Mapa das técnicas de avaliação



Atividade 1 · Viés de seleção (6–8 min)

Arquivo: `atividades/atividade_01_vies_selecao.R`

1. **Tarefa 1.** Varie a `forca_motivacao` (0, 0,5, 0,9, 1,5) e calcule o viés da comparação ingênua;
2. **Tarefa 2.** Gere uma população *sem* tendência e refaça o antes-depois.

Discutam (1 min):

- Quando a motivação não influencia a inscrição, o viés some por completo?
- Por que o antes-depois acertaria sem tendência — e isso é realista?

Gabarito comentado: `gabaritos/gabarito_01_vies_selecao.R` (liberado após a atividade).

Experimento controlado

Bloco 2 · 14:35 – 15:05 · Script 02 · Atividade 2

O “padrão ouro”: a aleatorização

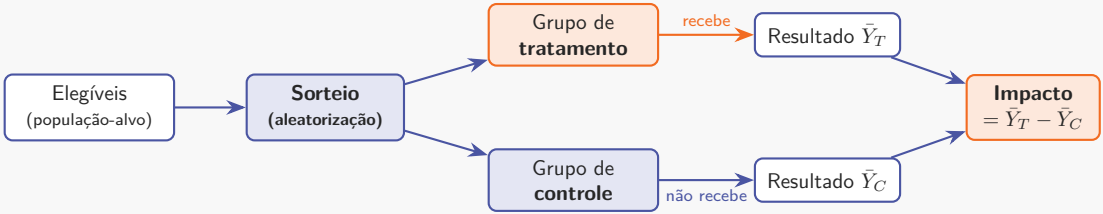
- Participantes são **distribuídos aleatoriamente** em dois grupos:
  - **Tratamento**: recebe a política;
  - **Controle**: não recebe.
- Todos têm a *mesma probabilidade* de cair em cada grupo $\Rightarrow$ os grupos são equivalentes **em média**, nas características observadas **e não observadas**;
- A única coisa que distingue os grupos é receber ou não a política: a diferença nos resultados é o impacto.

Atenção: o desenho vem antes

A avaliação experimental é definida no momento da **formulação** da política: é preciso medir o *baseline* e sortear *antes* de implementar.

Fonte: Batista e Domingos (2017), pp. 6–8.

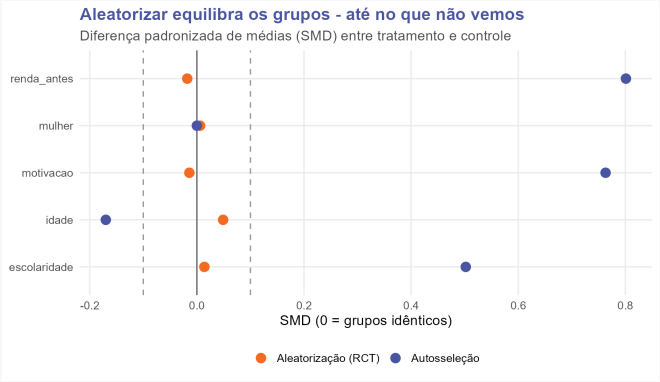
Como funciona um experimento de avaliação



Em termos estatísticos: **diferença de médias** (teste t) ou **regressão** em que a variável independente é uma *dummy* de tratamento.

Fonte: Batista e Domingos (2017), Figura 3 e pp. 6–7.

Por que funciona? Os grupos ficam equivalentes



- $|\text{SMD}| < 0{,}10$ = bom balanceamento;
- Com sorteio, *todas* as covariáveis ficam equilibradas — inclusive a **motivação**, que o avaliador não mede;
- Com autosseleção, a escolaridade, a renda e a motivação diferem fortemente.

Fonte: Simulação nossa (script 02). SMD = diferença padronizada de médias.

Estimando o efeito: diferença de médias e regressão

Diferença de médias

$\widehat{\text{Impacto}} = \bar{Y}_{\text{trat}} - \bar{Y}_{\text{ctrl}}$

Renda média: R$ 2.328 − R$ 2.033 = **R$ 295**

Regressão

$Y_i = \beta_0 + \beta_1 \, \text{Trat}_i + \varepsilon_i$

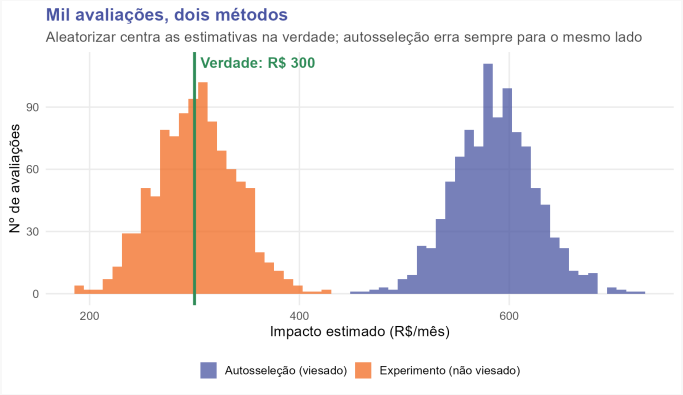
$\hat{\beta}_1$ é o impacto.

	Efeito	Erro-padrão
Sem covariáveis	295,2	11,4
Com covariáveis	302,1	**3,4**

Covariáveis não são necessárias para *eliminar* o viés (o sorteio já fez isso), mas deixam a estimativa mais **precisa**.

Verdade: R$ 300.

Mil avaliações, dois métodos (simulação de Monte Carlo)



Repetimos "a pesquisa" 1.000 vezes (amostras de 400 pessoas):

Método	Média
Autosseleção	587
Experimento	301

O sorteio é **não viesado**: erra para cima e para baixo, mas acerta *em média*. A autosseleção erra sempre para o mesmo lado.

Experimentos na avaliação de políticas: dois exemplos

Desparasitação no Quênia (PSDP)

- 75 escolas divididas em 3 grupos de 25 (1998–2001);
- **Implementação em fases**: grupo 1 recebe no 1.º ano; grupo 2 no 2.º; grupo 3 no 3.º;
- Crianças tratadas tiveram **melhor saúde** e **maior frequência escolar**.

Miguel e Kremer (2004).

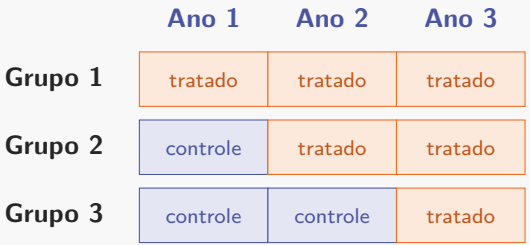
Seguro Popular (México)

- Acesso à saúde para famílias de baixa renda; 100 *clusters* randomizados;
- Gastos com saúde **caíram 23%** no grupo de tratamento (55% entre quem aderiu);
- Mas sem efeito substantivo no uso de serviços médicos.

King et al. (2009).

Fonte: Batista e Domingos (2017), p. 8.

Implementação em fases: sorteio que é também justiça



- Todos os elegíveis recebem a política *ao final do processo*, em ordem **sorteada**; quem espera funciona como controle;
- Com recursos escassos, dar a todos os elegíveis igual chance de participar — uma *loteria* — é uma das regras de alocação mais justas e transparentes (Gertler et al., 2011, citado no artigo).

Fonte: Batista e Domingos (2017), pp. 7–8.

Problemas no campo: *compliance*, atrito e *spillovers*

Compliance

Sorteados não aderem; ou o controle recebe o benefício por outro canal.

Na simulação (adesão de 70%): **ITT = R$ 193** (efeito da *oferta*); efeito sobre quem aderiu $\approx$ R$ 293.

Atrito

Indivíduos "saem" do grupo de tratamento (mudança, não resposta).

Se saem de forma *sistemática* (os que não melhoraram somem), o viés volta: estimativa de **R$ 345** (verdade: 300).

Spillovers

O tratamento "transborda" para o controle (ex.: vizinhos que compartilham informação).

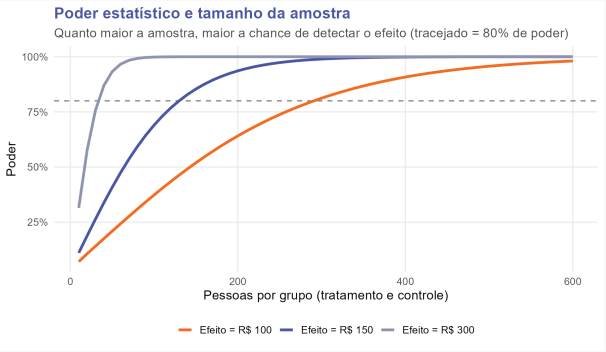
O controle é contaminado e a diferença *subestima* o efeito.

Esses problemas dificultam a interpretação, mas **não a inviabilizam** (Khandker, Koolwal e Samad, 2010).

Fonte: Batista e Domingos (2017), p. 7; números da simulação (script 02).

Poder estatístico: quantas pessoas são necessárias?

	Programa funciona	Não funciona
Detecta	acerto	**Erro tipo I**
Não detecta	**Erro tipo II**	acerto



- Poder $= 1 - P(\text{erro tipo II})$; meta usual: **80%**;
- Efeito de R$ 300: **34 pessoas por grupo**;
- Efeito de R$ 100: **291 por grupo**.

Fonte: Batista e Domingos (2017), p. 7. A análise de poder (`power.t.test`) deve ser feita *antes* do experimento (Gerber e Green, 2012).

Limites do experimento

- **Viabilidade**: exige desenhar a avaliação *antes* da implementação; se a política já foi distribuída de forma não aleatória, não há mais experimento;
- **Ética e aceitação**: sortear quem recebe pode parecer arbitrário ou antiético — mas, com recursos escassos, a loteria costuma ser a regra mais justa;
- **Custo e escala**: amostras grandes, acompanhamento de campo;
- **Validade externa**: o efeito vale para a população e o contexto do experimento.

Quando não dá para sortear...

As técnicas quase-experimentais tentam *emular* um grupo de controle com dados observacionais. É o que veremos a seguir.

Fonte: Batista e Domingos (2017), pp. 7–8.

Hora do R: 02_experimento_rct.R

▶ **Hora do R** · scripts/02_experimento_rct.R

```r
dados <- gerar_populacao(n = 5000, efeito = 300)

# 1. Sorteio: metade tratamento, metade controle
dados$tratamento <- sample(rep(0:1, length.out = nrow(dados)))
dados$renda_exp <- ifelse(dados$tratamento == 1,
                          dados$renda_depois_Y1, dados$renda_depois_Y0)

# 2. Impacto: diferenca de medias, teste t e regressao
t.test(renda_exp ~ tratamento, data = dados)
lm(renda_exp ~ tratamento, data = dados)

# 3. Quantas pessoas por grupo para detectar R$ 300 (poder 80%)?
power.t.test(delta = 300, sd = 430, power = 0.80)
```

Atividade 2 · Planejando um experimento (10 min)

Arquivo: `atividades/atividade_02_experimento.R`

1. **Tarefa 1.** Quantas pessoas por grupo para detectar R$ 100 com poder de 90%?
2. **Tarefa 2.** Estime o poder *por simulação* (100 pessoas por grupo, efeito de R$ 150) e compare com o valor teórico;
3. **Tarefa 3.** Reduza a adesão de 70% para 40%: o que acontece com o ITT e com o efeito sobre os aderentes?

Para discutir: qual medida o gestor deve usar para decidir expandir o programa — o ITT ou o efeito sobre quem aderiu?

Pareamento e propensity score

Bloco 3 · 15:05 – 15:40 · Script 03 · Atividade 3

E quando o experimento não é possível?

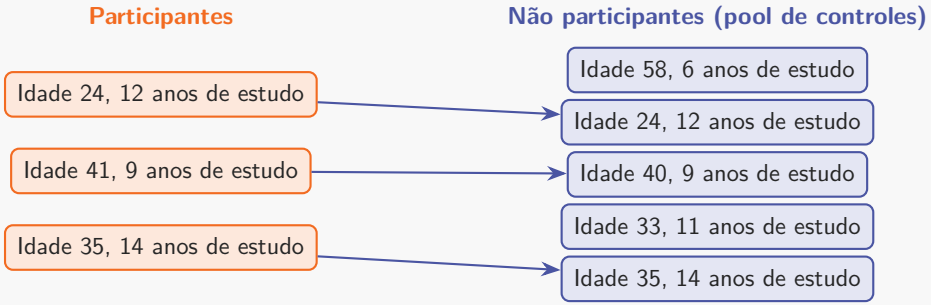
- A política já foi implementada, de forma não aleatória: não há separação *ex-ante* entre tratamento e controle;
- O que temos são **dados observacionais**: quem participou, quem não participou, e características de ambos;
- As **técnicas quase-experimentais** usam estatística para **emular** um grupo de controle.

Três técnicas que veremos

1. **Pareamento** (*matching*) e *propensity score*: compara indivíduos *parecidos*;
2. **Diferença-em-diferenças**: compara *variações* ao longo do tempo;
3. **Regressão descontínua**: explora uma *regra de elegibilidade*.

Fonte: Batista e Domingos (2017), p. 8.

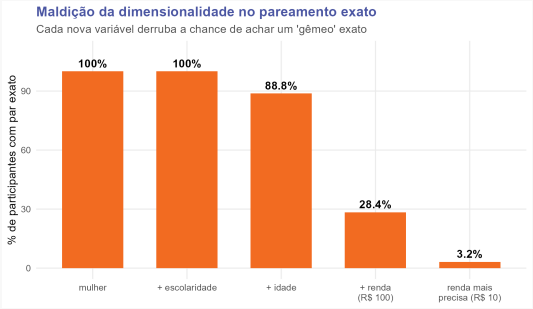
Pareamento: a ideia



- Para cada participante, encontrar não participantes **semelhantes nas características observadas**;
- Se, após igualar o que observamos, só o programa distingue os grupos, a diferença *ex-post* entre eles é atribuída à política.

Fonte: Batista e Domingos (2017), pp. 8–9; Figura 4.

Pareamento exato e a maldição da dimensionalidade



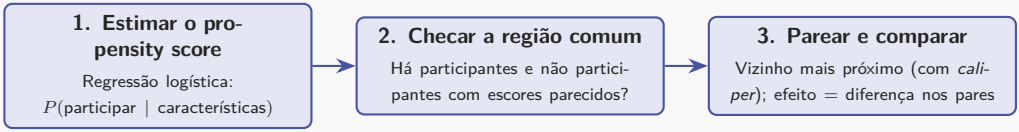
- **Pareamento exato**: o controle tem *exatamente* os mesmos atributos;
- Parece ideal, mas com muitas variáveis (ou variáveis quase contínuas) quase ninguém tem gêmeo exato;
- Na simulação: de 100% (com 2 variáveis) a **3%** (renda medida em dezenas de reais).

Solução (Rosenbaum e Rubin, 1983)

Resumir tudo em **um número**: a *probabilidade de participar*.

Fonte: Batista e Domingos (2017), pp. 8–9; simulação nossa (script 03).

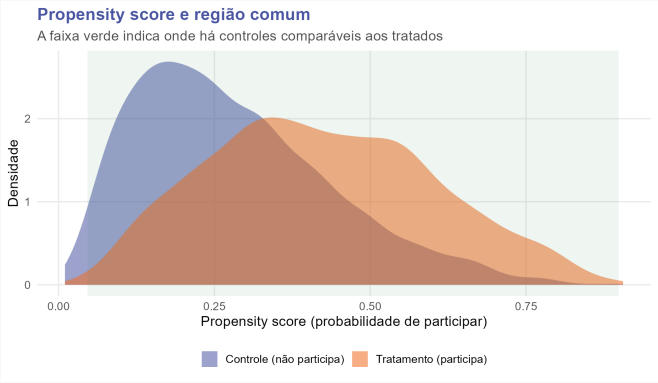
Propensity Score Matching (PSM) em 3 passos



- O pesquisador não encontra dois indivíduos idênticos, mas indivíduos **semelhantes o suficiente** na propensão de participar;
- Depois do pareamento, é obrigatório **checar o balanceamento** das covariáveis.

Fonte: Batista e Domingos (2017), pp. 9–10.

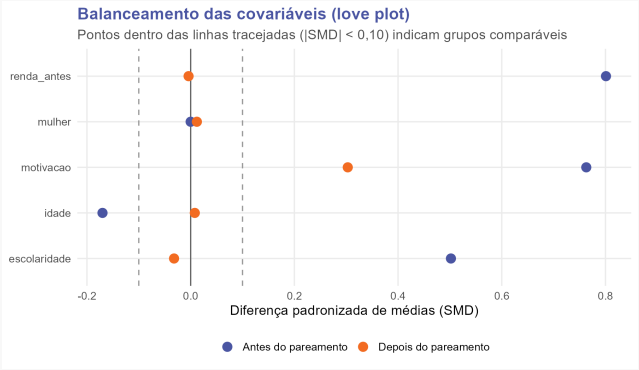
Região comum (suporte comum)



- Só dá para comparar quem tem "semelhantes" do outro grupo: é a **região comum**;
- Fora dela, tratados ficam sem par e saem da análise;
- Aqui a sobreposição é *boa*: 1.630 de 1.631 participantes encontram par.

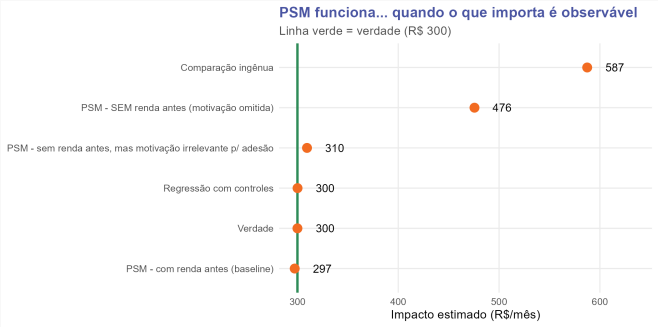
Fonte: Batista e Domingos (2017), Figura 5 (p. 10); simulação nossa.

Checando o balanceamento (*love plot*)



- Antes: participantes eram muito mais escolarizados e com maior renda anterior (SMD $\approx 0{,}5$ e $0{,}8$);
- Depois do pareamento, $|\text{SMD}| < 0{,}10$ nas variáveis do modelo;
- A **motivação** (não observada) melhora, mas continua desbalanceada (SMD $= 0{,}30$): o PSM só iguala o que está no modelo.

Resultado: quando o PSM acerta



- Com a renda *antes* do programa no modelo: **R$ 297** (EP bootstrap = 8,8; IC 95%: 280–315);
- Sem ela, a motivação omitida contamina: R$ 476;
- Quando a motivação não influencia a adesão, o PSM volta a acertar: R$ 310.

Fonte: Simulação nossa (script 03). Verdade = R$ 300.

Pressupostos e críticas ao PSM

Pressupostos

1. **Sem confundidores não observados**: fatores não medidos (ex.: autoestima, motivação) *não* afetam a participação nem o resultado;
2. **Região comum grande**: há indivíduos semelhantes participando e não participando.

Críticas

- King e Nielsen (2016): o PSM pode aumentar o desbalanceamento, que cresce com o nº de variáveis;
- Alternativa: **Coarsened Exact Matching** (CEM; Iacus, King e Porro, 2011/2012), que *garante* um desbalanceamento máximo escolhido *ex-ante*;
- Sempre: **mostre o balanceamento**.

Fonte: Batista e Domingos (2017), pp. 9–11.

PSM na avaliação de políticas: dois exemplos

Trabajar (Argentina, 1997)

Jalan e Ravallion (2003) analisam o programa argentino durante a crise econômica de 1997 e examinam os **ganhos de renda** dos beneficiários. O PSM usa variáveis socioeconômicas, do domicílio, demográficas e de histórico educacional. Com os escores estimados, separam tratamento e controle e não encontram efeitos positivos do programa.

Bolsa Família (Brasil)

MDS (2007): impacto sobre gasto de consumo, educação, trabalho infantil, antropometria, saúde e poder de barganha das mulheres. Dois grupos de comparação: elegíveis que recebem *outros* programas e não elegíveis; os participantes tiveram **melhor desempenho**.

Fonte: Batista e Domingos (2017), p. 10.

Hora do R: 03_pareamento_psm.R

▶ **Hora do R** · scripts/03_pareamento_psm.R

```r
# 1. Propensity score (regressao logistica)
m <- glm(participa ~ escolaridade + idade + mulher + renda_antes,
         data = dados, family = binomial)
dados$lps <- qlogis(predict(m, type = "response"))

# 2. Para cada tratado, o controle mais proximo (com caliper)
caliper <- 0.2 * sd(dados$lps)
for (k in seq_along(tratados)) {
  d <- abs(dados$lps[controles] - dados$lps[tratados[k]])
  if (min(d) <= caliper) par_controle[k] <- controles[which.min(d)]
}

# 3. Efeito sobre os tratados (ATT) e balanceamento (SMD)
mean(renda_tratados - renda_pares)                  # 297
```

Atividade 3 · Pareamento (10 min)

Arquivo: `atividades/atividade_03_pareamento.R`

1. **Tarefa 1.** Varie o *caliper* (0,01; 0,05; 0,2; 1) e observe o ATT e o nº de pareados;
2. **Tarefa 2.** Compare três especificações do propensity score: completa, sem renda antes, só renda antes;
3. **Tarefa 3.** Aumente a força da motivação (0, 0,9, 1,5): como evolui o erro do PSM sem a renda antes?

Para discutir: que pressuposto do PSM a Tarefa 3 ilustra? Que variável "tipo motivação" existe nas políticas que vocês conhecem?

Diferença-em-diferenças

Bloco 4 · 16:10 – 16:40 · Script 04 · Atividade 4

Diferença-em-diferenças: a ideia

- Compara a **variação** (depois − antes) do grupo **tratado** com a variação do grupo de **controle**;
- A variação do controle é a **tendência** que o tratado teria seguido sem a política;
- Elimina diferenças *fixas* entre os grupos — mesmo as **não observadas**;
- Usa *dois* "falsos contrafactuais" e os combina: a "dupla diferença".

Fórmula

$$\text{DD} = (\bar{Y}_T^{dep} - \bar{Y}_T^{ant}) - (\bar{Y}_C^{dep} - \bar{Y}_C^{ant})$$

Pressuposto-chave: **tendências paralelas** — sem a política, os dois grupos evoluiriam em paralelo.

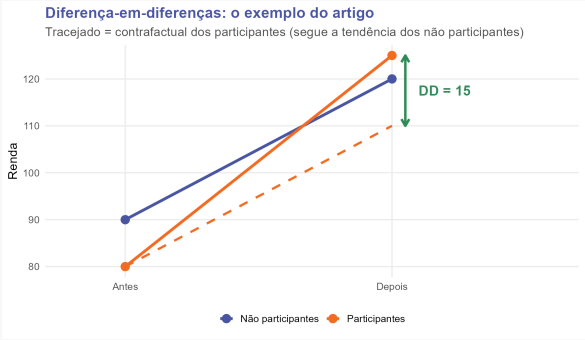
Fonte: Batista e Domingos (2017), pp. 11–12.

Exemplo do artigo, “na calculadora” (Figura 6)

Renda	Participantes	Não part.
Antes	80	90
Depois	125	120
Variação	**+45**	**+30**

Dupla diferença

$\text{DD} = 45 - 30 = \mathbf{15}$



Fonte: Batista e Domingos (2017), Figura 6 (p. 11), adaptada de Khandker, Koolwal e Samad (2010).

Dois “falsos contrafactuais” e o DD

Comparação	Estimativa	Problema
Antes $\times$ depois (participantes)	45	**superestima**: inclui a tendência ($+30$)
Participantes $\times$ não part. (depois)	5	**subestima**: ignora que partiam de nível
Diferença-em-diferenças	**15**	remove tendência *e* diferença fixa

- O DD aumenta a discricionariedade do avaliador: dependendo da técnica, recomenda-se manter ou interromper a política!

Fonte: Batista e Domingos (2017), p. 11.

DD por regressão: o coeficiente da interação

Modelo

$$Y_{it} = \beta_0 + \beta_1\,\text{Trat}_i + \beta_2\,\text{Pós}_t + \beta_3\,(\text{Trat}_i \times \text{Pós}_t) + \varepsilon_{it}$$

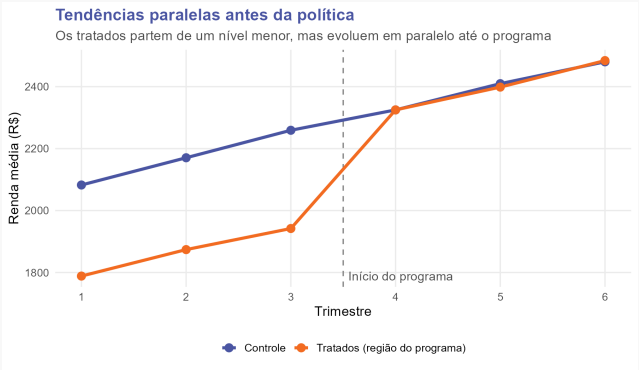
- β_1: diferença *fixa* entre os grupos;
- β_2: *tendência* comum;
- β_3: **efeito da política** (o DD).

Em dados reais, os erros de uma mesma unidade se repetem no tempo: use erros-padrão **agrupados** (*cluster*) por unidade, ou modelos com efeitos fixos de unidade e de tempo (pacote `fixest`).

Nossa simulação: **1.000 trabalhadores**, 6 trimestres, programa a partir do 4.º trimestre.

Fonte: Batista e Domingos (2017), p. 11.

Simulação: tendências paralelas antes do programa

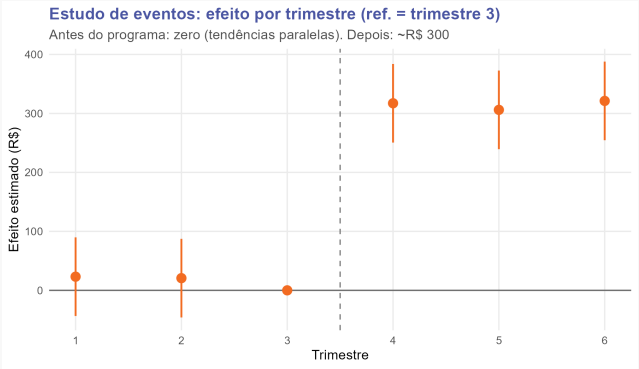


- Os tratados são *estruturalmente mais pobres* (efeito fixo $-$R\$ 300);
- Antes do trimestre 4, as linhas evoluem em **paralelo**;
- Depois, a distância muda: é o impacto ($+$R\$ 300).

Estimador	**R\$**
Antes $\times$ depois	535
Trat. $\times$ ctrl. (depois)	-2
DD	**300**

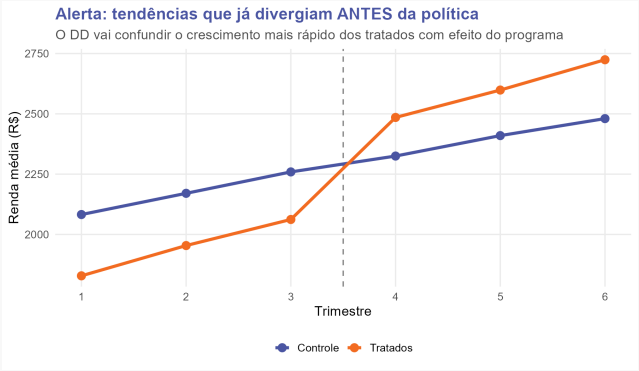
Fonte: Simulação nossa (script 04). Verdade = R\$ 300; EP agrupado por trabalhador = 7,8.

Testando o pressuposto: estudo de eventos e placebo



- **Estudo de eventos**: o efeito em *cada* período, em relação ao último antes da política;
- Antes do programa: coeficientes próximos de zero $\Rightarrow$ **sem pré-tendências**;
- **Placebo**: finja que a política começou antes (só com dados pré-programa): o DD deve ser ≈ 0 (aqui: -13);
- Isso *não prova* o pressuposto: é um indício.

Quando as tendências *não* são paralelas



Cenário: os tratados já cresciam R$ 40 a mais por trimestre.

- DD estimado: R$ 420 (verdade: 300);
- O DD atribui à política o crescimento *extra* que já existia;
- O placebo denuncia: +47 (longe de zero).

Se as características pré-tratamento variam no tempo, *combine PSM com DD*: primeiro pareie, depois calcule a dupla diferença entre os pares.

Fonte: Batista e Domingos (2017), p. 12.

Um caso real: a Lei Maria da Penha

- **Política**: lei nacional contra a violência de gênero — benefícios para *todas* as mulheres do país;
- **Problema**: como achar um grupo de controle?
- **Solução** (Cerqueira et al., 2015): **homens** como controle — expostos às outras causas gerais de violência, mas *não beneficiários*;
- **Resultado**: taxa de homicídio; **DD** = interação entre ser mulher e período pós-lei;
- A lei mostrou-se **efetiva**.

Para pensar

O que seriam "tendências paralelas" entre homicídios de mulheres e de homens? Que evento poderia afetar *os dois grupos de modo diferente* e violar o pressuposto?

Fonte: Batista e Domingos (2017), pp. 11–12.

Hora do R: 04_diferenca_em_diferenca.R

▶ **Hora do R** · scripts/04_diferenca_em_diferenca.R

```r
painel <- gerar_painel()        # 1.000 trabalhadores x 6 trimestres

# DD "na mao": quatro medias
m <- function(t, p) mean(painel$renda[painel$tratado == t & painel$pos == p])
(m(1, 1) - m(1, 0)) - (m(0, 1) - m(0, 0))          # 300

# DD por regressao: coeficiente da interacao
summary(lm(renda ~ tratado * pos, data = painel))

# Efeitos fixos de unidade e tempo, erro-padrao por cluster
library(fixest)
feols(renda ~ tratado:pos | id + trimestre, data = painel, cluster = ~id)
```

Atividade 4 · Diferença-em-diferenças (10 min)

Arquivo: `atividades/atividade_04_diferenca_em_diferenca.R`

1. **Tarefa 1.** DD "na calculadora" com a evasão escolar em escolas com e sem bolsa-permanência;
2. **Tarefa 2.** Gere um painel com tendência extra de R$ 20/trimestre para os tratados: o DD acerta? O placebo avisa?
3. **Desafio.** Gere um painel com efeito *zero*: o coeficiente de `tratado:pos` fica perto de zero?

Para discutir: no exemplo da Lei Maria da Penha, que choque poderia violar o pressuposto de tendências paralelas?

Regressão descontínua

Bloco 5 · 16:40 – 17:05 · Script 05 · Atividade 5

Regressão descontínua (RDD): um “experimento natural”

- Muitos programas têm uma **regra de elegibilidade**: um índice e um **ponto de corte** (*cutoff*);
- Quem está *logo abaixo* e *logo acima* do corte é muito semelhante, mas só um grupo recebe a política;
- Perto do corte, é **como se houvesse um sorteio** — que não está sob controle do avaliador;
- O impacto é o tamanho do **salto** (descontinuidade) no corte.

Fonte: Batista e Domingos (2017), pp. 12–13.

Dois pré-requisitos

1. Um índice de elegibilidade **contínuo**;
2. Um valor de corte **claramente definido**.

Duas limitações: efeito **local** (só perto do corte) e necessidade de **muitas observações** perto do corte.

Exemplo: transferência de renda com corte de pobreza

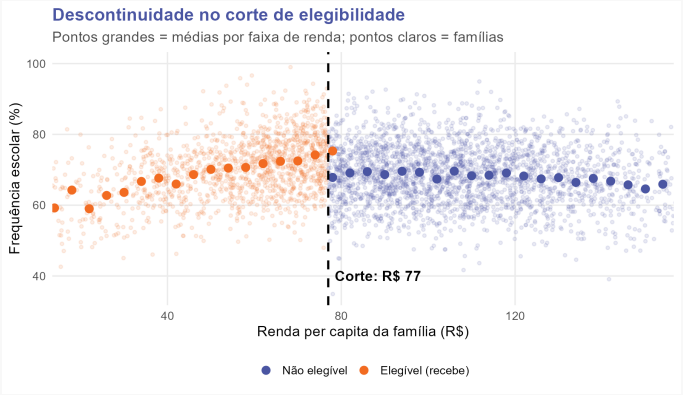
- Programa de transferência de renda: **elegível** quem tem renda per capita **até R$ 77** (linha de extrema pobreza, exemplo do artigo);
- Uma família com R$ 77 recebe; outra com R$ 78 *não*. Que diferença real existe entre elas?
- Dentro dessa faixa estreita, podemos tratar as famílias como *distribuídas aleatoriamente* entre tratamento e controle.

Nosso mundo simulado

- 4.000 famílias; resultado = **frequência escolar (%)**;
- Efeito verdadeiro: **+6 pontos percentuais**;
- A frequência cresce com a renda: elegíveis são mais pobres e, sem programa, teriam frequência *menor*.

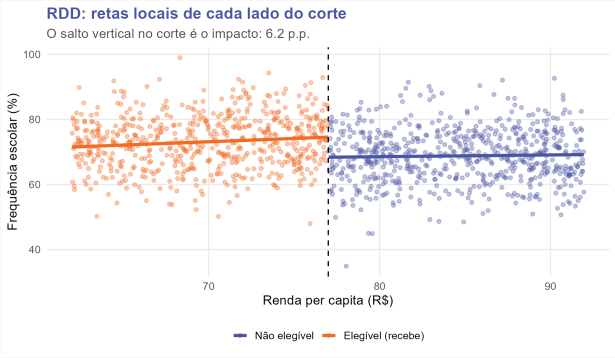
Fonte: Batista e Domingos (2017), pp. 12–13; Figura 7.

A descontinuidade no corte



- Os pontos grandes são médias por faixa de R$ 4 de renda;
- Há um **salto** em R$ 77: elegíveis (laranja) têm frequência maior logo abaixo do corte do que não elegíveis (índigo) logo acima;
- Longe do corte, a relação com a renda é *suave*: o salto só vem do programa.

Estimando: regressão linear *local*

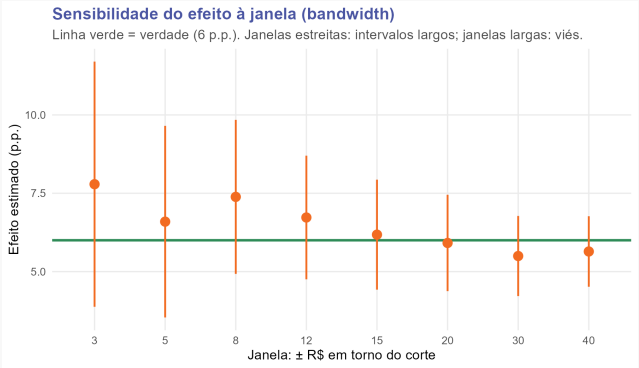


- Uma reta de cada lado, *só* com famílias numa janela em torno do corte (aqui, $\pm$ R$ 15);
- O coeficiente de `elegivel` é o salto: **6,2 p.p.** (EP = 0,9; verdade: 6);

Método	**Efeito (p.p.)**
Comparação simples	1,8
Reta global	4,7
Quadrática global	6,1
Local $\pm$15	**6,2**

Fonte: Batista e Domingos (2017), p. 13; simulação nossa (script 05).

A escolha da janela: viés × variância

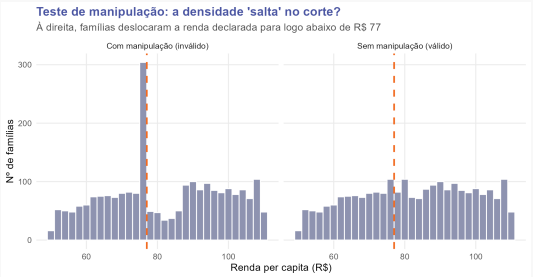


- **Janela estreita**: famílias mais comparáveis (menos viés), mas *poucas* (EP maior);
- **Janela larga**: mais observações (EP menor), mas menos comparáveis (mais viés);
- Boa prática: mostrar que o resultado **não depende** muito da janela. Pacote `rdrobust` escolhe uma janela ótima.

Testes de validade do desenho

Três checagens

1. **Covariáveis**: variáveis *pré-tratamento* (ex.: idade da mãe) não devem "pular" no corte (aqui: salto de $0{,}07$, EP $= 0{,}77$);
2. **Placebo**: cortes *falsos* (R$ 55, 65, 105) não devem gerar salto (aqui: ≈ 0);
3. **Manipulação**: as famílias conseguem ajustar a renda para entrar? Procure um *acúmulo* logo abaixo do corte.



Fonte: Simulação nossa (script 05).

Limites e variações do RDD

- **Efeito local**: o resultado vale para famílias *próximas do corte* (R$ 77), não necessariamente para quem ganha R$ 30;
- **Muitas observações** perto do corte são necessárias;
- **RDD "fuzzy"**: quando nem todos os elegíveis recebem, usa-se (salto no resultado) $\div$ (salto na participação). Na simulação: $5{,}4 \div 0{,}78 \approx 7{,}0$ (verdade: 6);
- **Não precisa ser "regressão"**: o essencial é verificar se as observações acima e abaixo do corte estão *balanceadas*.

Exemplo no artigo: Progresa (México)

Buddelmeyer e Skoufias (2004) comparam famílias elegíveis e inelegíveis no corte para avaliar o impacto na educação: aumento de **8,9%** (1998) e **9,9%** (1999) na presença escolar das **meninas**; para os meninos, +5% sem significância.

Fonte: Batista e Domingos (2017), pp. 12–13.

Hora do R: 05_regressao_descontinua.R

▶ Hora do R · scripts/05_regressao_descontinua.R

```r
d <- gerar_rdd()                # corte em R$ 77; x = renda - 77

# Regressao local: janela de +/- R$ 15, retas diferentes de cada lado
janela <- d[abs(d$x) <= 15, ]
m <- lm(freq ~ elegivel * x, data = janela)
coef(m)["elegivel"]                  # salto no corte: 6,2 p.p.

# Sensibilidade a janela
sapply(c(5, 15, 40), function(h) rdd_local(d, h)$efeito)

# Placebo: corte falso e teste de manipulacao (densidade da renda)
hist(d$renda, breaks = 60); abline(v = 77)
```

Atividade 5 · Regressão descontínua (8 min)

Arquivo: `atividades/atividade_05_regressao_descontinua.R`

1. **Tarefa 1.** Estime o efeito com janelas de ± 5, ± 15 e ± 40: compare o EP e o nº de famílias;
2. **Tarefa 2.** Mude o corte para R$ 70 e reestime;
3. **Tarefa 3.** Gere dados com *manipulação* da renda declarada: o que muda na estimativa? E nas contagens em torno do corte?

Para discutir: o efeito estimado vale para uma família com R$ 30 per capita? Por quê?

Técnicas qualitativas e métodos mistos

Bloco 6 · 17:05 – 17:50 · Atividade 6

Quantificar o impacto × compreender o impacto

Abordagem quantitativa

- **Quanto?** Magnitude do *efeito médio*;
- Foco no que é *geral*, comum;
- Lida com viés de seleção; busca o contrafactual;
- Generalização, replicação, transparência dos métodos.

Abordagem qualitativa

- **Como e por quê?** Qualidade da mudança;
- Foco no que é *específico*, no contexto e nos **significados** que os atores atribuem;
- Poucos casos, em profundidade;
- Valores, símbolos, percepções.

"Respondem a diferentes questões": o quantitativo *identifica*, o qualitativo *explica*.

Fonte: Batista e Domingos (2017), pp. 13–14, a partir de Patton (2002).

Por que incluir a perspectiva dos atores?

1. Parte da **perspectiva dos atores** para **reconstruir a política** (como foi implementada e percebida);
2. Identifica **impactos diferenciados** sobre diferentes grupos e indivíduos;
3. Analisa **dimensões não diretamente quantificáveis** (ex.: empoderamento, capital social);
4. Explica **por que** em algumas situações as políticas atingem os objetivos e em outras não: ajuda a "abrir a caixa-preta".

Uma metáfora do artigo (Patton, 2002)

Se você quer saber *quanto* pesam as pessoas, use uma balança. Se quer saber *o que o peso significa* para elas, é preciso ouvir suas histórias.

Fonte: Batista e Domingos (2017), pp. 14–15.

Observação e etnografia

- **Imersão** do pesquisador na cultura/grupo; notas de campo, descrições densas, contexto;
- **Participante** (torna-se membro funcional) ou **não participante** (apenas observa);
- O **tempo** é fator central: observações curtas geram interpretações parciais; longos períodos reduzem a *reflexividade* (o observado se comporta "diferente" na presença do pesquisador);
- Na avaliação: como a política é percebida no cotidiano e *como as pessoas reagem aos seus instrumentos*.

Fonte: Batista e Domingos (2017), pp. 15–16.

Adato (2008): PTCRs na Nicarágua e na Turquia

Surveys + etnografia + entrevistas. O survey dizia que o programa era bem *focalizado*, mas a **comunidade percebia o critério como arbitrário**; mães não davam o suplemento de ferro às crianças por julgarem que *fazia mal*; crianças eram superalimentadas antes da pesagem obrigatória para "passar no teste".

Entrevistas em profundidade

- A *palavra* do participante é o foco; perguntas **abertas e flexíveis**, em oposição aos questionários fechados;
- Tipos: **estruturada**, **semiestruturada** (tópicos-guia), **não estruturada** e **narrativa**;
- O entrevistador precisa construir **confiança** e preparar um tópico-guia com progressão lógica;
- Útil para aprofundar um tema, mapear percepções individuais ou temas *sensíveis*.

Fonte: Batista e Domingos (2017), pp. 16–17.

Patton (2002): programa de alfabetização de adultos

O survey registrou que **77% estavam "muito satisfeitos"**. As entrevistas mostraram *por quê*: ler os frascos de remédio das crianças, ler a Bíblia, fazer compras — ênfase no **empoderamento** cotidiano, não na colocação no mercado de trabalho (objetivo principal do programa).

Grupos focais

- **Não** é a soma de entrevistas individuais: o foco está na **discussão e deliberação** entre os participantes;
- O moderador *fomenta* a discussão, limita dominantes, incentiva quem fala pouco e mantém o tema;
- Bom para explorar o *espectro* de atitudes e opiniões e observar **consenso e divergência**.

Hunter e Sugiyama (2014): Bolsa Família

11 grupos focais em 3 municípios do Nordeste (Camaragibe, Jaboatão dos Guararapes e Pau-Brasil) + entrevistas com gestores. Sugerem que o programa deu **dignidade** às famílias (compra de comida, roupas e material escolar), autonomia frente ao clientelismo e senso de **empoderamento**.

Fonte: Batista e Domingos (2017), pp. 17–18.

Críticas comuns — e cuidados

Críticas

- Subjetividade e especificidade dos resultados;
- Ausência de *regularidades* ou generalização;
- Menor precisão;
- Dificuldade de *replicação*.

Cuidados e respostas

- **Representatividade** como **variabilidade** (incluir posições diferentes), não como probabilidade estatística;
- Selecionar casos usando evidência *quantitativa* (evita viés);
- Tempo de campo, treinamento do entrevistador, tópico-guia;
- Menos intrusiva: considera a percepção dos próprios atores.

Fonte: Batista e Domingos (2017), pp. 14, 18–19.

Combinando métodos: o que se ganha

1. **Validade e credibilidade**: convergência ao medir o mesmo fenômeno (*triangulação*);
2. **Compreensividade**: capta diferentes dimensões sob perspectivas distintas;
3. **Descoberta** de fatores inesperados;
4. **Diversidade** de olhares.

Regra de ouro: nenhum método é sempre o mais apropriado. O método deve ser escolhido pela **pergunta** que se quer responder.

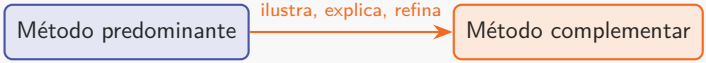
Ideia de Worthen, Sanders e Fitzpatrick (1997), citados no artigo

Greene, Benjamin e Goodyear (2001): quatro contribuições do multimétodo para a avaliação.

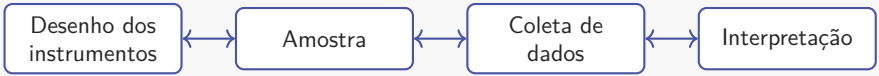
Fonte: Batista e Domingos (2017), pp. 18–19.

Coordenados ou integrados?

Coordenado: combinação no final do estudo



Integrado: pontos de interação ao longo de todo o estudo



Os métodos quantitativo e qualitativo se alimentam mutuamente em cada etapa.

- Predominantemente quantitativo: o qualitativo *formula instrumentos* e *explica* os resultados;
- Predominantemente qualitativo: o quantitativo *seleciona casos* e mostra que eles são representativos dos grupos.

Fonte: Batista e Domingos (2017), pp. 18–19; Figura 8, adaptada de Bamberger (2012); Caracelli e Greene (1997).

Exemplos de métodos mistos no artigo

Chile: focalização

Clert e Wodon (2001): **survey** nacional mostra grande sucesso na focalização. **Grupos focais** revelam o que o número escondia: beneficiários não entendem as regras e sentem *injustiça* na distribuição.

Uruguai: exclusão social

Baker (2001): **métodos quantitativos** escolhem as áreas geográficas e os grupos vulneráveis; **entrevistas e grupos focais** exploram as dimensões e percepções da exclusão. Qualitativo predominante.

Índia: desenvolvimento comunitário

Bamberger (2012), abordagem **integrada**: 200 comunidades sorteadas (tratamento) $\rightarrow$ pesquisa exploratória $\rightarrow$ survey $\rightarrow$ estudo em profundidade de 5 projetos tratados e 5 controles $\rightarrow$ **triangulação**.

Fonte: Batista e Domingos (2017), pp. 19–20.

Atividade 6 · Do número ao porquê (15 min, em grupos)

Cenário

O DiD do **Qualifica** mostrou **+R$ 300**. Mas: (1) o efeito é *muito menor* entre mulheres com filhos pequenos (R$ 80); (2) 35% dos inscritos abandonaram o curso; (3) 80% se dizem "muito satisfeitos", mas o gestor acha que "algo não bate".

Em grupos de 3–4 pessoas (salas simultâneas):

1. **Parte A**: qual técnica responde a cada pergunta (impacto, motivo das diferenças, rotina do curso, significado de "satisfeito")?
2. **Parte B**: escrevam **4 perguntas abertas** para entrevistar mulheres que abandonaram o curso;
3. **Parte C**: o desenho de vocês é *coordenado* ou *integrado*? Que risco metodológico vocês enxergam?

Roteiro completo: `atividades/atividade_06_qualitativo_metodos_mistos.md`. Plenária: 10 min.

Síntese: qual técnica usar?

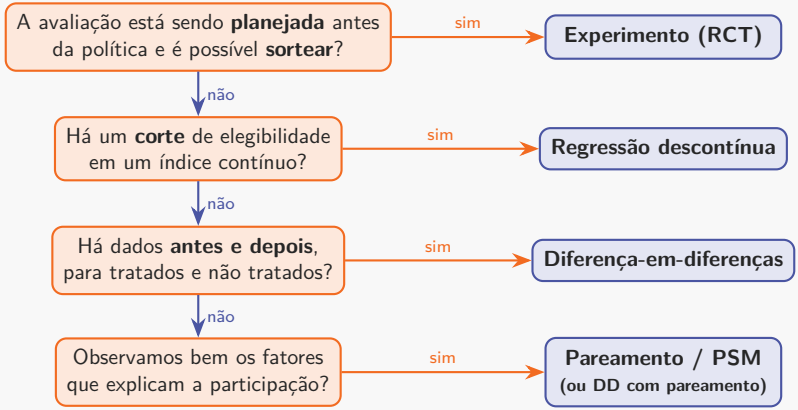
Encerramento · 17:50 – 18:00

As quatro técnicas lado a lado

	Experimento	Pareamento (PSM)	Dif.-em-dif.	Regr. descontínua
Contrafactual vem de...	Sorteio entre elegíveis	Não participantes *parecidos*	Tendência do grupo de controle	Quem está do outro lado do corte
Pressuposto-chave	Sorteio bem executado	Sem confundidores *não observados*; região comum	**Tendências paralelas**	Sem manipulação do corte; continuidade
Dados necessários	Baseline e follow-up desenhados *ex-ante*	Muitas covariáveis; um período	Pelo menos 2 períodos, tratados e controles	Índice contínuo e corte claro; muitas obs. no corte
Teste/diagnóstico	Balanceamento; *compliance*; atrito	Balanceamento (SMD); região comum	Pré-tendências; placebo	Janela; covariáveis; manipulação; placebo
Limitação	Custo, ética, validade externa	Viés se faltar variável relevante	Choques diferenciais	Efeito *local*
Em nossa simulação	R$ 295–302	R$ 297 (sem baseline: 476)	R$ 300 (violado: 420)	6,2 p.p. (verdade: 6)

Fonte: Batista e Domingos (2017), pp. 6–13; simulações dos scripts 02 a 05.

Qual técnica usar? Um roteiro de decisão



Fonte: Síntese nossa a partir de Batista e Domingos (2017). Na prática, combine sempre com métodos qualitativos.

Cinco perguntas antes de confiar em uma estimativa

1. **Qual é o contrafactual?** De onde ele vem e por que é crível?
2. **Quais grupos estão sendo comparados** e eles eram parecidos *antes*? (balanceamento, pré-tendências)
3. **Qual pressuposto sustenta o resultado?** Ele foi testado ou só declarado?
4. **Para quem vale o efeito?** (população do experimento, tratados, *no corte*)
5. **O que o número não mostra?** Quem ganhou mais, quem ganhou menos, e *por quê*?

Lembrete do artigo

A discricionariedade do avaliador é grande: o mesmo programa pode ser recomendado ou interrompido dependendo da técnica escolhida (vimos $45 \times 5 \times 15$ no DiD).

Mensagem final: mais que boas intenções

- O experimento é o *padrão ouro*, mas nem sempre viável: por isso existem as técnicas **quase-experimentais**;
- Elas **emulam** um grupo de controle, cada uma com seus pressupostos: **diga quais são, teste o que puder**;
- Estimar o impacto **médio** é essencial para decidir manter ou interromper políticas — mas ele não mostra as *pessoas por trás dos números*;
- Combinar métodos aumenta a contribuição de cada um: **quanto** e **por quê**.

Fonte: Batista e Domingos (2017), Conclusão (p. 20).

Para levar para casa

- Rodar de novo os scripts, mudando parâmetros;
- Escolher uma política que vocês estudam e responder às 5 perguntas;
- Desenhar, ainda que em esboço, como *seria* a avaliação ideal.

Para continuar: leituras

- **Batista, M. e Domingos, A. (2017).** Mais que boas intenções: técnicas quantitativas e qualitativas na avaliação de impacto de políticas públicas. *Revista Brasileira de Ciências Sociais*, 32(94), e329414. doi.org/10.17666/329414/2017
- **Gertler, P. et al. (2011).** *Impact Evaluation in Practice*. World Bank.
- **Khandker, S., Koolwal, G. e Samad, H. (2010).** *Handbook on Impact Evaluation: Quantitative Methods and Practices*. World Bank.
- **Glennerster, R. e Takavarasha, K. (2013).** *Running Randomized Evaluations*. Princeton UP.
- **Dunning, T. (2012).** *Natural Experiments in the Social Sciences*. Cambridge UP.
- **Ipea / Casa Civil.** *Avaliação de Políticas Públicas: Guia Prático de Análise ex-Ante* e *ex-Post* (gratuitos, no portal do governo federal).
- **Patton, M. (2002).** *Qualitative Research and Evaluation Methods*. Sage.
- **Bauer, M. e Gaskell, G. (2010).** *Pesquisa qualitativa com texto, imagem e som*. Vozes.

Repositório do curso e contato

- **GitHub**:
  `github.com/andersonheri/avaliacao-pp-each`
- Pastas: `slides/`, `scripts/` (R comentado), `atividades/`, `gabaritos/`, `material/`
- Tudo é reproduzível: mudem as sementes, os efeitos, os tamanhos de amostra

Anderson Henrique
Pós-doutorando CEM/USP (FAPESP/CEPid) · INCT-QualiGov · IPEA
andersonheri@gmail.com

Feedback (2 min)

O que funcionou? O que mudariam? Que técnica vocês querem aprofundar?

Respondam no chat ou por e-mail.

Obrigado!

Perguntas, críticas e sugestões